Uma Análise aos Algoritmos de Filtragem Colaborativa Baseada em Memória e Modelo

DAVI CARDOSO DE OLIVEIRA**, Universidade Federal Rural do Rio de Janeiro, Brasil

Sistemas de recomendação são ferramentas essenciais para navegar na vasta quantidade de informações disponíveis em plataformas de e-commerce e streaming. Este trabalho foca na implementação e análise comparativa de algoritmos de filtragem colaborativa, o pilar de muitos desses sistemas. Explorei duas abordagens principais: uma baseada em memória, representada pelo User-based Collaborative Filtering, e outra baseada em modelo, o Improved Regularized SVD. Utilizando a base de dados MovieLens 100k, investiguei o impacto da hiperparametrização no desempenho de cada algoritmo, avaliando-os com métricas de acurácia (MAE) e de qualidade da recomendação (Precision e Recall).

CCS Concepts: • **Information systems → Recommender systems**.

Additional Key Words and Phrases: Sistemas de Recomendação, Filtragem Colaborativa, Fatoração de Matrizes, User-Based, SVD

ACM Reference Format:
Davi Cardoso de Oliveira. 2025. Uma Análise aos Algoritmos de Filtragem Colaborativa Baseada em Memória e Modelo. *ACM Trans. Graph.* 37, 4, Article 111 (June 2025), 2 pages. https://doi.org/10.1145/nnnnnnn.nnnnnnn

1 Introdução

Atualmente, há um crescimento exponencial no número de usuários que utilizam sistemas de comércio eletrônico. Esses sites oferecem uma vasta gama de produtos e serviços, o que pode sobrecarregar os consumidores em suas decisões de compra ou consumo. Os Sistemas de Recomendação (SR) têm desempenhado um papel importante ao auxiliar os usuários a encontrar produtos e serviços relevantes [1].

Grande parte das pesquisas em SR se concentra na melhoria dos algoritmos de previsão para aprimorar a acurácia [3]. A competição Netflix Prize demonstrou que havia muitas oportunidades para melhorar significativamente a acurácia dos algoritmos [2]. Desde então, surgiram pesquisas focadas em problemas como a esparsidade dos dados e a personalização das recomendações, que influenciam diretamente o desempenho dos recomendadores.

A filtragem colaborativa (FC) é uma das abordagens mais bem-sucedidas, baseada na ideia de que as preferências de um usuário podem ser inferidas a partir das preferências de uma comunidade de usuários com gostos similares. Os métodos de FC podem ser agrupados em duas classes principais: baseados em memória e baseados em modelo. O objetivo deste trabalho é implementar e comparar um algoritmo representativo de cada classe, ajustando seus hiperparâmetros e avaliando seu desempenho em múltiplas frentes para determinar a abordagem mais eficaz no contexto do dataset MovieLens 100k.

2 Metodologia Experimental

Nesta seção, detalho a base de dados, a metodologia de avaliação e os algoritmos implementados.

2.1 Base de Dados

O conjunto de dados utilizado foi o **MovieLens 100k**, um benchmark clássico na área. Ele contém 100.000 avaliações, variando de 1 a 5, atribuídas por 943 usuários a 1.682 filmes.

2.2 Metodologia de Avaliação

Para uma avaliação robusta, o dataset foi dividido em 80% para treinamento e 20% para teste. Utilizei duas categorias de métricas:

(1) **Métricas de Acurácia de Predição:** Medem o quão próximas as notas previstas ($\hat{r}_{ui}$) estão das notas reais (r_{ui}). Utilizei o **Erro Médio Absoluto (MAE)**.
(2) **Métricas de Qualidade da Recomendação:** Avaliam a relevância da lista de "top-N" itens recomendados. Para isso, considerei um item como "relevante" se o usuário o avaliou com 4 ou 5 estrelas no conjunto de teste.
   - **Precision:** A proporção de itens relevantes dentro da lista de 10 principais recomendações.
   - **Recall:** A proporção de itens relevantes que o sistema conseguiu recomendar na lista de 10 principais itens.

2.3 Algoritmos Implementados

2.3.1 Filtragem Colaborativa Baseada em Memória: User-Based CF. Esta abordagem se baseia no princípio de que usuários com gostos similares no passado tenderão a ter gostos similares no futuro. A previsão da nota $\hat{r}_{ui}$ é calculada como uma média ponderada das notas dos vizinhos, ajustada pela média de avaliação de cada usuário. Para medir a similaridade, utilizei a **Correlação de Pearson (PC)**. Sendo o hiperparâmetro chave o k, o número de vizinhos.

2.3.2 Filtragem Colaborativa Baseada em Modelo: Improved Regularized SVD. Esta abordagem aprende um modelo de fatores latentes para representar usuários e itens. A previsão da nota é calculada incorporando os vieses (μ, b_u, b_i) com a interação dos fatores latentes (p_u, q_i):

$$\hat{r}_{ui} = \mu + b_u + b_i + q_i^T p_u$$

Os parâmetros são aprendidos via **Descida de Gradiente Estocástico (SGD)**. O hiperparâmetro principal é o número de fatores latentes.

*Trabalho final para a disciplina de Sistemas de Recomendação da graduação em Ciências da Computação

Author's Contact Information: Davi Cardoso de Oliveira, davideoliveira2003@gmail.com, Universidade Federal Rural do Rio de Janeiro, Nova Iguaçu, Rio de Janeiro, Brasil.

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.
© 2025 Copyright held by the owner/author(s). Publication rights licensed to ACM.
ACM 1557-7368/2025/6-ART111
https://doi.org/10.1145/nnnnnnn.nnnnnnn

3 Resultados e Análise

3.1 Análise de Acurácia e Hiperparâmetros

A Figura 1 ilustra o impacto dos hiperparâmetros no desempenho de cada algoritmo.

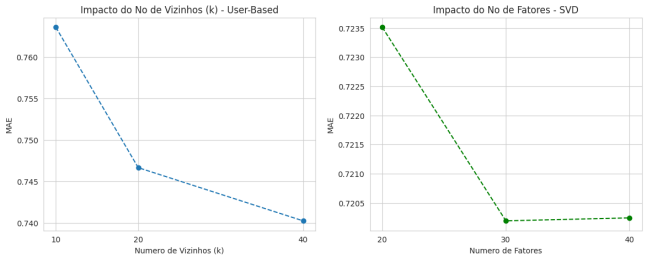

Fig. 1. Impacto dos Hiperparâmetros no MAE dos Modelos.

Para o **User-Based CF** (gráfico à esquerda), o erro (MAE) diminui com o aumento de k, pois o modelo se torna mais estável. O melhor desempenho foi alcançado com **k=40**. Já para o **Improved SVD** (gráfico à direita), a análise da execução final revelou um comportamento diferente. O desempenho melhorou significativamente ao passar de 20 para 30 fatores, e então se estabilizou, com o MAE permanecendo o mesmo para 40 fatores. Isso sugere que o modelo atingiu sua capacidade máxima de aprendizado com 30 fatores nesta execução específica; adicionar mais complexidade não trouxe benefícios adicionais. Portanto, considerei então **30 fatores** como o ponto ótimo. A Tabela 1 resume o melhor desempenho de cada um.

Table 1. Melhor Desempenho de Acurácia (MAE).

Algoritmo	Hiperparâmetro Ótimo	Melhor MAE
User-based CF	k = 40	0.7403
Improved SVD	Fatores = 30	**0.7202**

3.2 Análise da Qualidade da Recomendação

Avaliei também a capacidade dos modelos em gerar uma lista de "top 10" recomendações úteis. Os resultados são apresentados na Tabela 2.

Table 2. Resultados de Precision e Recall.

Algoritmo	Precision	Recall
User-based CF (k=40)	0.0067	0.0049
Improved SVD (Fatores=30)	**0.0790**	**0.0510**

A **superioridade do Improved SVD na qualidade da recomendação é ainda mais expressiva**. Com uma precisão de 7.9%, ele se mostrou quase **12 vezes mais eficaz** que o User-Based CF (0.67%) em apresentar itens relevantes na lista de recomendações. Esse resultado mostra a força da fatoração de matrizes em generalizar as preferências latentes dos usuários para descobrir novos itens de interesse, ou seja, encontra "gostos ocultos" do usuário em comum para acertar na nova recomendação.

4 Conclusão

Este trabalho comparou detalhadamente abordagens de filtragem colaborativa baseadas em memória e em modelo. A análise combinada das métricas de acurácia (MAE) e de qualidade da recomendação (Precision/Recall) aponta para uma conclusão inequívoca: para o dataset MovieLens 100k, a abordagem baseada em modelo **(Improved Regularized SVD) é superior em todos os aspectos avaliados**.

Concluindo, o SVD não só acerta mais as notas, como também funciona muito melhor para criar listas de recomendações que o usuário vai gostar. Isso mostra como os modelos de fatoração de matrizes são importantes atualmente, principalmente pela sua precisão e estabilidade mesmo quando faltam muitas notas (a esparsidade).

References

[1] G. Adomavicius and A. Tuzhilin. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6):734–749, 2005.
[2] Y. Koren, R. Bell, and C. Volinsky. Matrix factorization techniques for recommender systems. *Computer*, 42(8):30–37, 2009.
[3] F. Ricci, L. Rokach, B. Shapira, and P. B. Kantor. *Recommender Systems Handbook*. Springer, 2011.

Received 30 June 2025; revised 30 June 2025; accepted 30 June 2025